

Natural Language Processing

Catedrático: Javier Josué Fong Guzmán

Estudiante: Juan Diego Letona Aguilar

Laboratorio #4

Entrega 23 de agosto, 2026



20230285

Laboratorio #4 - Modelos Lineales



I. Construcción del clasificador de regresión logística

Se entrenaron dos modelos LogisticRegression para clasificar las siete categorías del corpus. El primero utilizó la matriz de Bolsa de Palabras (BoW) y el segundo la matriz TF-IDF. Para mantener una comparación justa con el Laboratorio #3 se reutilizaron exactamente las mismas particiones estratificadas de entrenamiento, validación y prueba, así como los mismos vectorizadores ya ajustados únicamente con el conjunto de entrenamiento. Por lo tanto, no se realizó nuevamente ningún fit de los vectorizadores. En regresión logística, x representa las características del documento, w los pesos aprendidos y b el sesgo. La expresión $z = w \cdot x + b$ genera un puntaje para cada clase. En clasificación binaria, la sigmoide convierte ese puntaje en una probabilidad entre 0 y 1. En este problema multiclase, el modelo calcula probabilidades para las siete categorías y selecciona la que tenga el valor más alto.

II. Entrenamiento y evaluación

En validación, BoW obtuvo accuracy de 0.8772, precision, recall y F1 macro de 0.9080, 0.7913 y 0.8130, y precision, recall y F1 ponderados de 0.8853, 0.8772 y 0.8717. TF-IDF obtuvo accuracy de 0.8538, métricas macro de 0.7631, 0.7292 y 0.7357, y ponderadas de 0.8492, 0.8538 y 0.8417. En prueba, BoW alcanzó accuracy de 0.8655, precisión/recall/F1 macro de 0.8742/0.8404/0.8516 y valores ponderados de 0.8746/0.8655/0.8671. TF-IDF obtuvo accuracy de 0.7895, métricas macro de 0.8324/0.6858/0.6987 y ponderadas de 0.8146/0.7895/0.7714.

Existen indicios de overfitting. BoW pasó de F1 macro 1.0000 en entrenamiento a 0.8130 en validación, una diferencia de 0.1870. TF-IDF paso de 0.9167 a 0.7357, diferencia de 0.1810. Esto indica que ambos modelos se ajustan mejor a los ejemplos conocidos que a datos nuevos. Sin embargo, BoW conserva un comportamiento relativamente estable entre validación y prueba y finalmente obtiene el mejor rendimiento. Por ello, BoW fue la mejor representación para regresión logística. Una posible explicación es que, para este corpus, la frecuencia directa de ciertas palabras conserva información discriminativa importante que TF-IDF reduce al ponderar términos frecuentes.



III. Interpretación de pesos

En general, los resultados tienen sentido. Términos como "alianza", "acuerdo" y "aliado" favorecen claramente la categoría Alianzas, mientras que "gasto", "interés", "débito" y "entidad" resultan más discriminativos para Otra. También aparecen algunos términos poco interpretables, lo que demuestra que un coeficiente alto no siempre implica una relación semántica clara con la categoría. Al compararlos con las palabras más importantes de Naive Bayes hubo poca coincidencia, 4 de 15 en Alianzas y 3 de 15 en Otra. Naive Bayes tendió a destacar palabras más generales y frecuentes, mientras que regresion logistica encontró términos más útiles para distinguir una categoría de las demás. Esto se debe a que Naive Bayes evalúa la evidencia de cada palabra de forma individual, mientras que regresion logistica aprende los pesos de todas las características conjuntamente.

palabra_positiva	peso_positivo	palabra_negativa	peso_negativo
alianza	0.979700	bbva	-0.774700
compañía	0.255600	regulación	-0.283100
colombia	0.226400	podcast	-0.259500
acuerdo	0.221700	reputación	-0.165400
acceso	0.220100	sostenible	-0.152800
aliado	0.206700	si	-0.146900
colombiano	0.200000	hablar	-0.141400
programa	0.193900	global	-0.140400
anunciar	0.192300	trabajo	-0.137700
millón	0.185700	activo	-0.132700
presidente	0.184800	responsable	-0.129200
político	0.172900	sistema	-0.125000
pacífico	0.169900	importante	-0.122600
marca	0.163000	inflación	-0.120900
colombio	0.160900	principal	-0.120100

palabra_positiva	peso_positivo	palabra_negativa	peso_negativo
bbva	0.341000	alianza	-0.240900
colombia	0.290800	tecnología	-0.174900
asegurar	0.265500	`	-0.174400
frente	0.251800	él	-0.173200
entidad	0.250000	2022	-0.168300
gasto	0.236000	empresa	-0.161700
interés	0.228600	podcast	-0.154800
carrera	0.224800	seguro	-0.153000
hacer	0.217600	innovación	-0.149100
débito	0.211200	comercio	-0.146900
través	0.210500	permitir	-0.140500
bogotá	0.196600	españa	-0.139000
presidente	0.193500	así	-0.135700
mujer	0.183600	cómo	-0.135000
inversionista	0.183400	negocio	-0.123200

IV. Comparación con Naive Bayes

	modelo	representacion	accuracy	f1_macro	f1_ponderado	tiempo_entrenamiento_s
0	Naive Bayes	BoW	0.7953	0.7132	0.7803	0.0154
1	Naive Bayes	TF-IDF	0.5497	0.3121	0.4411	0.0145
2	Regresion logistica	BoW	0.8655	0.8516	0.8671	2.4652
3	Regresion logistica	TF-IDF	0.7895	0.6987	0.7714	1.4473

El mejor modelo fue Regresión Logística con BoW. Frente a Naive Bayes con BoW, mejoró aproximadamente 0.07 en accuracy y 0.14 en F1 macro, por lo que la diferencia fue marginal. Con

TF-IDF, la ventaja de regresión logística fue todavía mayor. Esto se relaciona con la forma en que ambos modelos aprenden. Naive Bayes calcula la evidencia de cada palabra bajo el supuesto de independencia, mientras que regresión logística ajusta todos los pesos de manera conjunta para separar mejor las categorías. La principal desventaja fue el tiempo de entrenamiento, ya que Naive Bayes tardó aproximadamente entre 0.01 y 0.02 segundos, mientras que regresión logística necesitó entre 1.0 y 4.0 segundos.

V. Análisis de errores

La principal confusión del mejor modelo fue entre Otra y Sostenibilidad. Se encontraron cuatro noticias cuya categoría real era Otra pero fueron clasificadas como Sostenibilidad. Los cuatro errores pueden explicarse por las palabras presentes en los documentos. En el documento 988 destacaron "sostenible" con 0.7308, "renovable" con 0.6176 y "objetivo" con 0.5994. En el 426, "sostenible" alcanzó 1.0962, seguido de "objetivo", "climático" y "responsable". En el 696 también tuvieron alta contribución "sostenible", "climático", "objetivo" y "sostenibilidad". Finalmente, en el documento 0 destacaron "sostenible", "negocio", "mundo" y "climático". Por lo tanto, los errores no fueron aleatorios. Aunque estos documentos estaban etiquetados como Otra, contenían varias características fuertemente relacionadas con Sostenibilidad, lo que llevó al modelo a clasificarlos en esa categoría.

VI. Analisis

1. Ambos son clasificadores lineales, pero obtienen la evidencia de forma distinta. Naive Bayes calcula la importancia de cada palabra según su frecuencia dentro de una categoría y asume independencia entre características, mientras que regresión logística aprende todos los pesos conjuntamente para separar mejor las clases. Sección 3 / celda 84: al comparar las palabras más importantes, solo coincidieron 4 de 15 en Alianzas y 3 de 15 en Otra entre Naive Bayes y regresión logística. Eso muestra que, aunque ambos son lineales, no llegan a los pesos de la misma forma. Sección 4 / celda 88: con BoW, regresión logística obtuvo F1 macro = 0.8516 frente a 0.7132 de Naive Bayes, además de accuracy 0.8655 vs 0.7953. Eso apoya que la optimización conjunta de pesos de regresión logística separó mejor las clases en este corpus.
2. Si hay evidencia clara de esta diferencia. En Alianzas, Naive Bayes destacó palabras generales como "poder", "país", "hacer" y "nuevo", mientras que regresión logística dio mayor importancia a términos más discriminativos como "alianza", "acuerdo" y "aliado". La diferencia también se

observa en los errores. Ambos modelos clasificaron los mismos cuatro documentos de "Otra" como "Sostenibilidad". Naive Bayes acumula la evidencia de palabras relacionadas de forma independiente, mientras que regresión logística ajusta sus pesos conjuntamente. Sin embargo, en estos casos la evidencia hacia Sostenibilidad fue suficientemente fuerte para que ambos cometieron el mismo error.

3. Preferiría Naive Bayes cuando el corpus sea pequeño, necesite entrenar o actualizar el modelo rápidamente y quiere una interpretación sencilla. En nuestros resultados entrenó en aproximadamente 0.01 a 0.02 segundos, por lo que sería útil cuando la velocidad sea una prioridad. Preferiría regresión logística cuando busque un mejor desempeño predictivo y pueda dedicar más tiempo al entrenamiento. En nuestro caso, aunque tardó aproximadamente entre 1.0 y 4.0 segundos, obtuvo resultados claramente superiores. También permite interpretar qué características favorecen o perjudican cada categoría mediante sus coeficientes.
4. La categoría mayoritaria en prueba es Macroeconomía, con 48 de 171 documentos. Esto significa que un modelo que siempre predice "Macroeconomía" obtendría un accuracy de solo 28.07%, muy por debajo del desempeño de los modelos entrenados. Un modelo que siempre predice esa categoría obtiene un accuracy de 0.2807 y un F1 macro de 0.0626. Todos los modelos superan ampliamente esta línea base. Naive Bayes con BoW alcanza 0.7953 de accuracy y regresión logística con BoW llega a 0.8655. Esto demuestra que los modelos aprendieron patrones reales del texto y no simplemente a predecir la categoría más frecuente.
5. Para poner un modelo en producción no consideraría solo accuracy. También evaluaré F1 macro, tiempo de inferencia, tamaño del modelo, interpretabilidad, calidad de las probabilidades y costo de reentrenamiento. En este caso elegiría regresión logística con BoW, ya que obtuvo el mejor desempeño con 0.8655 de accuracy y 0.8516 de F1 macro. Aunque Naive Bayes entrena mucho más rápido, el tiempo de entrenamiento de regresión logística sigue siendo bajo para este corpus. Solo preferiría Naive Bayes si necesitará entrenar con mucha frecuencia o tuviera restricciones fuertes de computo.

<https://github.com/JuanDi37/Laboratorio-4-NLP>